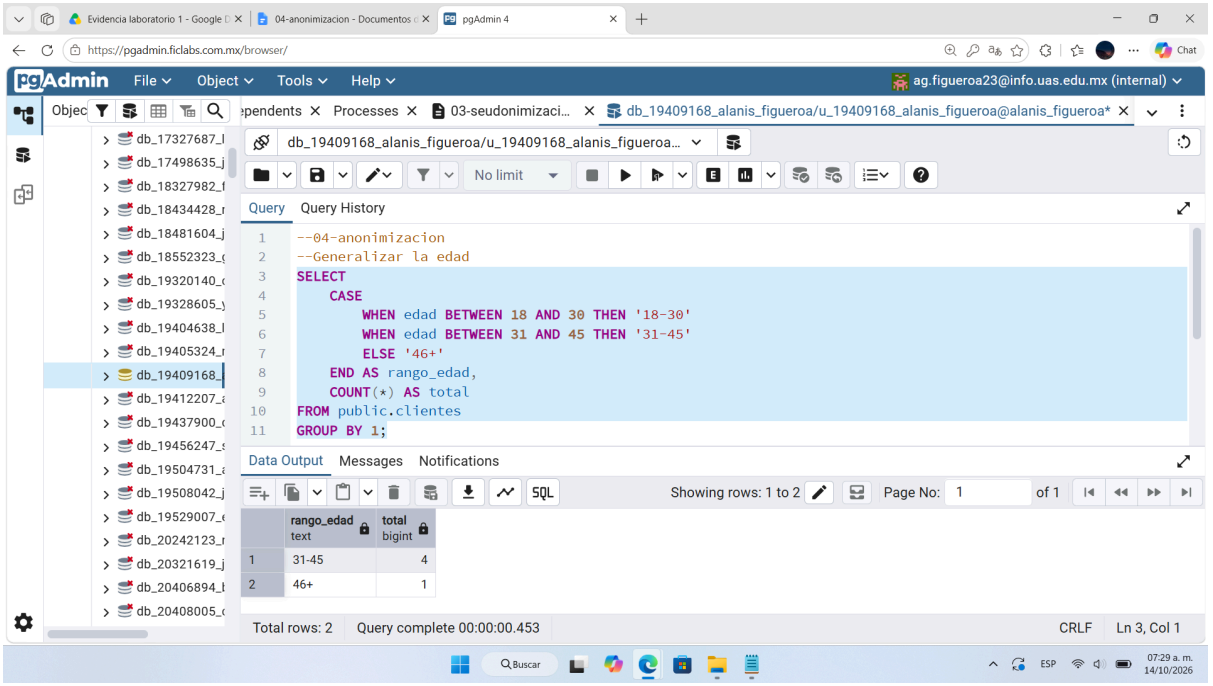
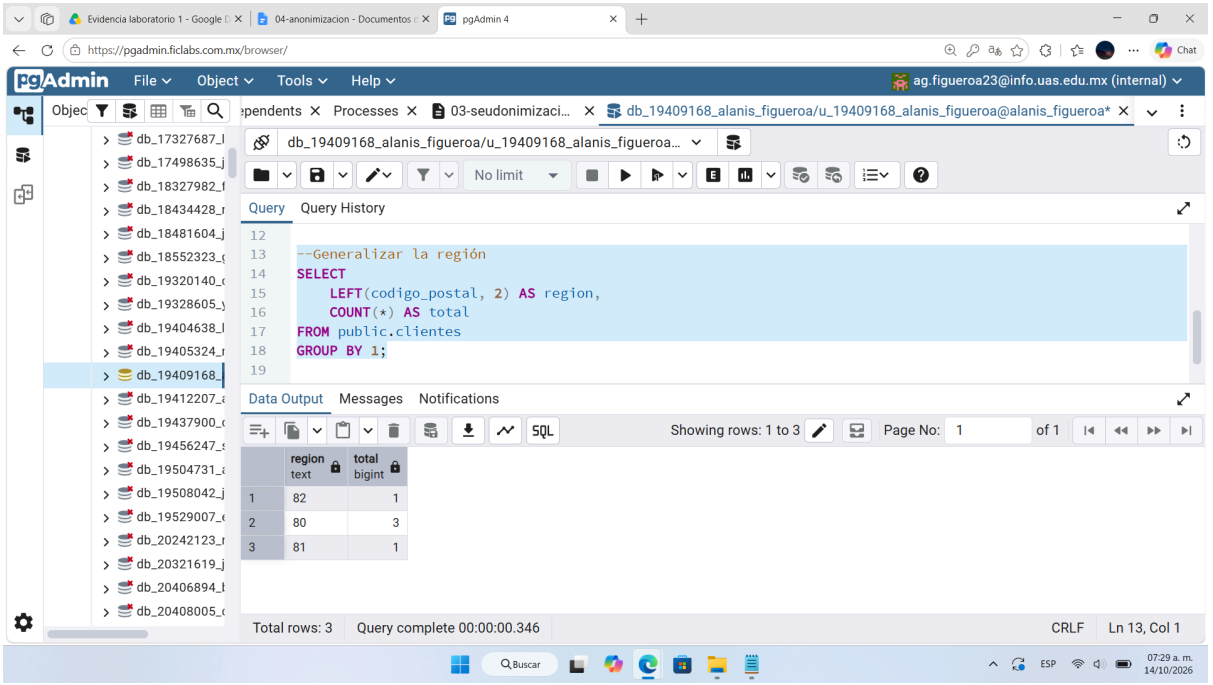
Actividad 5 — Anonimización (anonymization)

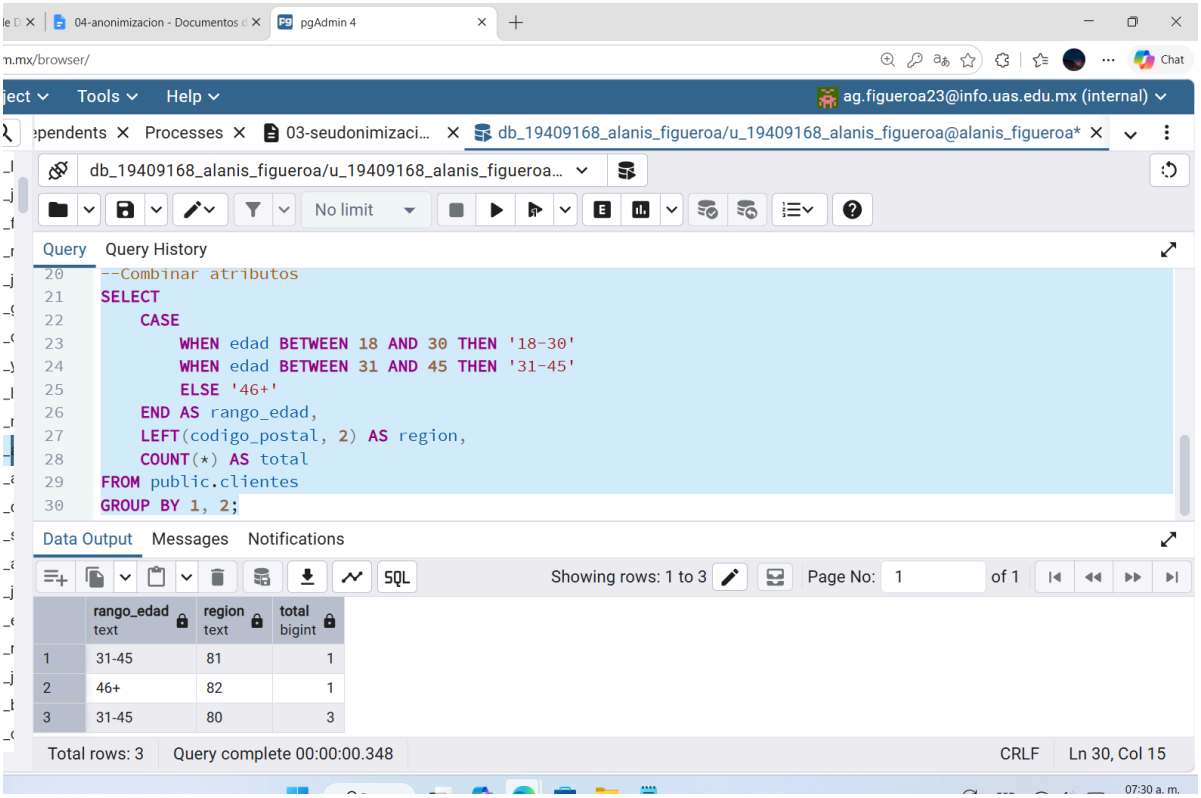
Generalizar la edad



Generalizar la región

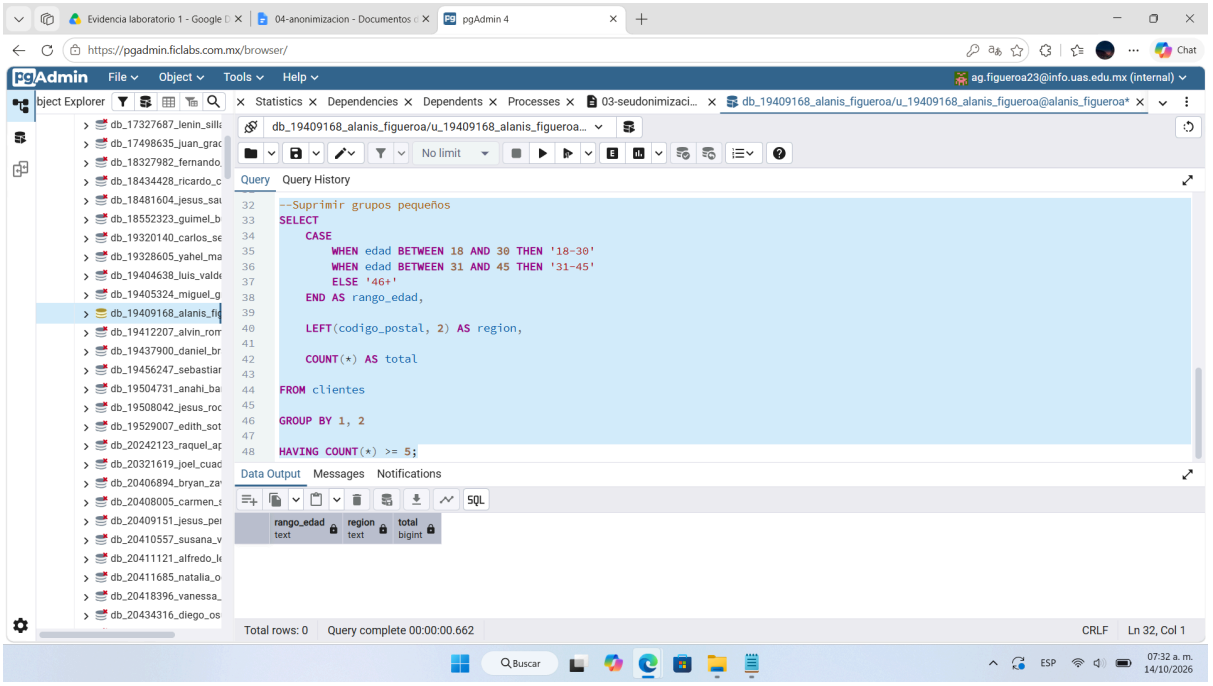


Combinar atributos



Suprimir grupos pequeños

Como ejercicio didáctico se utilizará un umbral de cinco registros:



Como la tabla tiene cinco clientes, es posible que no aparezca ninguna fila.

Actividad 6 — Análisis del riesgo de reidentificación

1. ¿Qué identificadores directos fueron eliminados?

Se eliminaron los identificadores directos como el nombre, el correo electrónico, el teléfono y el RFC de la tabla utilizada para el análisis. Estos datos permiten identificar directamente a una persona, por lo que no se incluyen en el conjunto analítico.

2. ¿Qué cuasi-identificadores permanecen?

Permanecen atributos como la edad, la ciudad, el código postal y la fecha de alta. Aunque estos datos no identifican necesariamente a una persona por sí solos, al combinarlos con otras fuentes de información podrían facilitar su identificación.

3. ¿Qué combinaciones de atributos podrían reducir el anonimato?

Las combinaciones de edad, ciudad, código postal y fecha de alta pueden reducir el anonimato, especialmente cuando corresponden a pocas personas. Por ejemplo, una persona que vive en una región específica, pertenece a un rango de edad poco común y se registró en una fecha determinada podría ser más fácil de reconocer.

4. ¿Qué sucede cuando un grupo contiene pocos registros?

Cuando un grupo contiene pocos registros, aumenta el riesgo de reidentificación porque hay menos personas entre las cuales podría encontrarse el individuo. Por ello, se pueden suprimir los grupos pequeños o generalizar sus atributos para aumentar la cantidad de personas que comparten características similares.

5. ¿Qué atributos deberían generalizarse?

Se podrían generalizar la edad mediante rangos más amplios, el código postal mediante regiones menos específicas y la fecha de alta mediante el mes o el año. También podría utilizarse una región geográfica más amplia en lugar de la ciudad exacta.

6. ¿Qué información debería suprimirse?

Se deberían suprimir las combinaciones de atributos que permitan distinguir a una persona con facilidad, especialmente aquellas que correspondan a grupos muy pequeños. Si después de generalizar los datos todavía existe un riesgo elevado, se podrían eliminar algunos cuasi-identificadores que no sean necesarios para el análisis.

7. ¿Es correcto afirmar que el conjunto de datos es “100 % anónimo”? ¿Por qué?

No es correcto afirmar que el conjunto de datos es 100 % anónimo únicamente porque se eliminaron los identificadores directos. Los cuasi-identificadores pueden combinarse entre sí o con información externa para reconocer a una persona. La anonimización requiere evaluar el riesgo de reidentificación según los datos disponibles, su finalidad y las posibles fuentes externas de información.

Reto — Modificar la consulta para reducir el riesgo

Como en la actividad anterior utilizaste `HAVING COUNT(*) >= 5`, podemos mejorar la consulta generalizando la edad en rangos más amplios y utilizando solamente los dos primeros dígitos del código postal. Así se evita mostrar la edad exacta y el código postal completo.

Cambio realizado: Se ampliaron los rangos de edad y se conservaron únicamente los dos primeros dígitos del código postal. Además, se mantuvo la condición `HAVING COUNT(*) >= 5` para mostrar únicamente grupos con cinco o más registros.

Motivo: Reducir la precisión de los cuasi-identificadores y evitar la publicación de grupos demasiado pequeños, disminuyendo la posibilidad de reconocer a un cliente.

Resultado obtenido: La consulta muestra únicamente las combinaciones de rango de edad y región que contienen al menos cinco clientes. Si no aparece ninguna fila, significa que ninguno de los grupos cumple con ese mínimo; no significa que la consulta haya fallado.

Riesgo que se pretende reducir: Se busca disminuir la posibilidad de reidentificación mediante la combinación de la edad y la ubicación geográfica. Sin embargo, este cambio no garantiza por sí solo la anonimización completa del conjunto de datos.

